

Exoesqueleto Adaptativo para Niños con Parálisis Cerebral

Clasificación de la marcha mediante deep learning
como base para el control adaptativo del dispositivo

01

Contexto y Motivación

La heterogeneidad clínica de la diplejía espástica exige tratamientos personalizados

Parálisis cerebral: impacto en la marcha

¿Qué es?

- Grupo de trastornos permanentes del movimiento que aparecen en la infancia temprana.
- No es progresivo, pero sus manifestaciones cambian con el desarrollo.
- Síntomas: coordinación deficiente, espasticidad, debilidad muscular.
- Tratamiento multidisciplinar: fisioterapia, farmacología, cirugía funcional.

17M+ *

personas con PC en el mundo

2-3 *

casos por cada 1,000 nacidos vivos

~70% *

de casos con PC son de tipo espástica

El desafío clave

Dentro del espectro de la PC, la diplegia espástica tiene 4 formas clínicas distintas. Cada una requiere una intervención diferente. Hoy, la clasificación debe ser realizada por un experto clínico.

* <https://www.gob.mx/insabi/articulos/dia-mundial-de-la-paralisis-cerebral-06-de-octubre> y McIntyre et al. (2022), Dev Med Child Neurol; Oskoui et al. (2013)

Las 4 formas de diplejía espástica (Ferrari et al.)

Forma I

Antepulsión del tronco. Equilibrio en punta de pies. Apoyo constante en bastones.

Forma II

Flexión pronunciada de rodilla en apoyo medio (crouch gait). Pasos cortos. Comportamiento de rodilla cargada.

Forma III

Oscilación frontal de tronco y uso de miembros superiores para equilibrio. Trastornos perceptivos: miedo a caer.

Forma IV

Déficit principalmente motor. Aumento del talipes equinus al iniciar la marcha. Dificultad para detenerse.

Clasificación por Ferrari et al. — ordenadas de mayor a menor limitación en el repertorio motor central. Clasificación estrechamente asociada al GMFCS.

02

Dataset y Metodología

174 pacientes, 1121 ensayos, sistema optoelectrónico VICON en el laboratorio LAMBDA

El laboratorio LAMBDA y el dataset

174

pacientes con diplejía
espástica

1121

ensayos de marcha
capturados

27

parámetros angulares
extraídos por frame


Adquisición

- Sistema VICON (8 cámaras MX+)
- 19 marcadores opto-electrónicos en puntos anatómicos clave
- 100 fps → submuestreado a 50 fps
- Formato C3D → procesado a .npy (coordenadas 3D + flag de validación)

Dataset público

- Liberado tras publicación del paper (2019)
- 1139 ensayos / 178 pacientes (versión completa en GitHub)
- Distribución desbalanceada: Forma 4 es la más numerosa
- Forma 1 con augmentación de datos (repetición de trials)

El laboratorio LAMBDA y el dataset



Identifier	Marker position
C7	7th cervical vertebrae
LA	Left acromioclavicular joint
RA	Right acromioclavicular joint
REP	Right lateral elbow epicondyle
LEP	Left lateral elbow epicondyle
RUL	Right lateral prominence of the ulna
LUL	Left lateral prominence of the ulna
RASIS	Right anterior superior iliac spine
LASIS	Left anterior superior iliac spine
RPSIS	Right posterior superior iliac spine
LPSIS	Left posterior superior iliac spine
RGT	Right prominence of the greater trochanter
LGT	Left prominence of the greater trochanter
RLE	Right lateral knee epicondyle
LLE	Left lateral knee epicondyle
RCA	Right upper ridge of the calcaneus posterior surface
LCA	Left upper ridge of the calcaneus posterior surface
RFM	Right dorsal aspect of first metatarsal head
LFM	Left dorsal aspect of first metatarsal head

Preprocesamiento: 5 transformaciones de los datos

01

**Identificar
período T**

Strikes y toe-offs
detectados visualmente

02

**Selección de
pasos completos**

Se descartan pasos
incompletos

03

3D → ángulos

81 ángulos/frame
(27 × 3 planos)

04

FFT

20 armónicos por
ángulo (frecuencia)

05

Secuencias


75 elementos
cada una

Representación final:

LSTM – secuencias de 75 elementos × 81 ángulos | MLP – vector de 1,620 coeficientes de Fourier

- **MLP:** recibe features estáticas de Fourier (sin información temporal).
- **LSTM:** recibe la secuencia completa y captura la dinámica temporal de la marcha.

Preprocesamiento: 5 transformaciones de los datos



03

Clasificación con Deep Learning

Dos arquitecturas evaluadas: MLP con FFT y LSTM con datos secuenciales

Arquitecturas evaluadas: MLP vs LSTM

MLP

Red Neuronal Multicapa

Entrada:	1620 coeficientes FFT
Capas:	256 → 128 → 64 → Dropout(0.2) → 32
Salida:	4 clases (Softmax)
Optimizer:	Adam, batch 100
Tiempo:	~10 s por entrenamiento


LSTM

Red Neuronal Recurrente

Entrada:	Secuencias 75 × 81 ángulos
Capas:	LSTM(32) → 1024 → 496 → 64 → 32
Salida:	4 clases (Softmax)
Optimizer:	Adam, 15 épocas
Tiempo:	~240 s por entrenamiento

Resultados: precisión de clasificación

El LSTM clasifica correctamente 3 de las 4 formas con accuracy comparable al experto humano



Hallazgos clave

- Formas I, II y IV: clasificación precisa con top-1.
- Forma III: el componente perceptivo (miedo a caer) no aparece en los datos cinemáticos — limitación inherente.
- LSTM > MLP en 6.5 pp, ambos superan SVM en >28 pp.
- Resultados del LSTM son equivalentes a los de clínicos expertos en 3 de 4 formas.

Conclusiones

1

Clasificación automática de diplejía con 86.9% de precisión.

El LSTM sobre datos secuenciales de marcha iguala al experto clínico en 3 de 4 formas, con un dataset de 174 pacientes y 27 parámetros angulares.

2

El análisis cuantitativo de marcha es viable y reproducible.

El dataset LAMBDA (público) provee la base de datos etiquetada necesaria para entrenar el módulo clasificador del exoesqueleto.

3

La Forma III exige sensores adicionales.

El componente perceptivo de esta forma no es captura por cinemática pura — el diseño del hardware debe incorporar IMUs, presión plantar y posiblemente EMG.

4

La personalización es técnicamente posible.

Clasificar la forma de diplejía en tiempo real permite adaptar dinámicamente los parámetros de torque del exoesqueleto a cada paciente.

Referencias

- [1] Ferrari, A. et al. (2019). Gait-Based Diplegia Classification Using LSTM Networks. Journal of Healthcare Engineering, vol. 2019, art. 3796898. DOI: 10.1155/2019/3796898
- [2] Ferrari, A. et al. (2008). The term diplegia should be enhanced. Part I: a new rehabilitation oriented classification of cerebral palsy. European Journal of Physical and Rehabilitation Medicine, 44(2), 195–201.
- [3] Bergamini, L. et al. (2017). Signal Processing and Machine Learning for Diplegia Classification. Int. Conference on Image Analysis and Processing (ICIAP), pp. 97–108. Springer.
- [4] Lerner, Z.F., Damiano, D.L., Bulea, T.C. (2017). Effects of Exoskeleton Assisted Knee Extension on Gait in Children with Cerebral Palsy. Scientific Reports, 7, 13512.
- [5] Dataset LAMBDA — lucabergamini/gait-analysis-dataset. GitHub. <https://github.com/lucabergamini/gait-analysis-dataset>