

Clasificación de Patrones de Marcha en Parálisis Cerebral: Revisión de Literatura

¹ Manuela Valencia Franco

¹Ingeniería Matemática, Universidad EAFIT, mvalenciaf@eafit.edu.co

2026-1

Entendimiento del problema

Motivación

La Parálisis Cerebral (PC) es un trastorno permanente del movimiento y la postura originado por alteraciones en el cerebro. El objetivo de este proyecto es construir modelos que identifiquen el tipo de PC y reconozcan las fases del ciclo de marcha, como base para sistemas de asistencia robótica (exoesqueletos) adaptados a cada paciente.



Detección de fase

Le indica al robot CUÁNDO debe actuar: por ejemplo, dar soporte durante el apoyo o asistir el levantamiento en el despegue del pie (eventos IC / FO del ciclo de marcha).



Clasificación de tipo de PC

Le indica al robot CÓMO debe actuar. Un niño con Jump Gait (Forma II) necesita una asistencia distinta a uno con Crouch Gait (Forma IV), por sus diferentes posturas de cadera y rodilla.

Figure: Dos preguntas que el modelo debe resolver: cuándo actúa el exoesqueleto y cómo debe actuar

Una estrategia de transferencia en tres etapas

El proyecto sigue una estrategia de transferencia en tres etapas, donde el conocimiento biomecánico fluye desde un modelo masivo de laboratorio hacia una aplicación específica, y finalmente hacia una validación independiente.




Figure: Flujo de transferencia de conocimiento: de IntellEvent a SimTK cp-child-gait.

Problema: Domain Shift

¿Qué es Domain Shift?

Ocurre cuando la distribución de los datos de prueba difiere de la usada en entrenamiento. En este caso, un modelo entrenado solo con datos VICON puede degradarse fuertemente al recibir señales reales de IMU.



VICON · Estándar de oro

- Sistema óptico de alta precisión.
- Costoso y restringido a entornos de laboratorio.
- Es la fuente de los datos de entrenamiento.



IMU · Sensor del exoesqueleto

- Portátil y económico.
- Señales ruidosas, con deriva (drift) en el tiempo.
- Es la modalidad real de operación del robot.

Figure: VICON frente a IMU

Tipos de Domain Shift

La literatura identifica tres formas en que puede cambiar la distribución de los datos: el Prior Shift (cambia la distribución de clases), el Covariate Shift (cambia la distribución de entrada, manteniendo la relación con la etiqueta) y el Concept Shift (cambia el significado de las etiquetas). En este proyecto, el foco está en el Covariate Shift entre los datos VICON y los sensores IMU



Prior Shift

Cambia $p(y)$

La distribución de clases cambia, pero $p(x|y)$ se mantiene. Ej.: entrenar con muchos niños con diparesia y evaluar en una población con más casos de desarrollo típico.



Covariate Shift

Cambia $p(x)$

La distribución de entrada cambia, pero $p(y|x)$ se mantiene estable. Es el más relevante aquí: la transición de mediciones VICON precisas a señales IMU más ruidosas.



Concept Shift

Cambia $p(y|x)$

El significado de las etiquetas se modifica. Ej.: un patrón antes considerado normal podría reclasificarse como patológico al actualizar criterios clínicos.

Figure: Tres clases de Domain Shift

Técnicas de adaptación

DANN, MMD y el Aprendizaje Contrastivo (NT-Xent) son las técnicas candidatas para alinear las representaciones de VICON e IMU en el espacio latente del encoder BiLSTM. Difieren en sus supuestos sobre el dominio, su necesidad de datos pareados y su complejidad de implementación



DANN *Adversarial*

Un discriminador de dominio compite con el clasificador; obliga al encoder a aprender rasgos útiles para la PC pero ciegos al tipo de sensor.

No requiere datos pareados · Complejidad media



MMD *Alineación estadística*

Minimiza la discrepancia entre las distribuciones de ambos dominios en el espacio latente como pérdida adicional, estable y fácil de integrar.

No requiere datos pareados · Complejidad baja



Contrastivo *NT-Xent*

Alinea ciclos de marcha similares entre dominios; funciona sin etiquetas en el dominio objetivo (IMU), ideal para aprendizaje semi-supervisado.

Se beneficia de datos pareados · Complejidad alta

Figure: Tres causas de degradación del desempeño

Referencias



Dumphart, B., Slijepcevic, D., Zeppelzauer, M., Kranzl, A., Unglaube, F., Baca, A. y Horsak, B. (2023). *Robust Deep Learning-Based Gait Event Detection Across Various Pathologies*. PLOS ONE, 18(8), e0288555. DOI: 10.1371/journal.pone.0288555.



Ferrari, A., Bergamini, L., Guerzoni, G., Calderara, S., Bicocchi, N., Vitetta, G., Borghi, C., Neviani, R. y Ferrari, A. (2019). *Gait-Based Diplegia Classification Using LSTM Networks*. *Journal of Healthcare Engineering*, 2019, 3796898. DOI: 10.1155/2019/3796898.



Kamboj, A. y Do, M. (2024). *A Survey of IMU Based Cross-Modal Transfer Learning in Human Activity Recognition*. arXiv preprint arXiv:2403.15444.



Kouw, W. M. y Loog, M. (2019). *An Introduction to Domain Adaptation and Transfer Learning*. arXiv preprint arXiv:1812.11806.



Ganin, Y., Ustinova, E., Ajakan, H., Germain, P., Larochelle, H., Laviolette, F., Marchand, M. y Lempitsky, V. (2016). *Domain-Adversarial Training of Neural Networks*. *Journal of Machine Learning Research*, 17(59), 1–35.